

# Privacidade Diferencial

João Gabriel Borges Monteiro  
Felipe dos Reis



# Pseudo-código do kNN Diferencial

**Entrada:** Conjunto de Treino ( $X_{train}, Y_{train}$ ), Instância de Teste  $X_{query}$ , Hiperparâmetro  $kk$ , Orçamento de privacidade  $\epsilon$ .

**Saída:** Classe prevista  $y^{\wedge}$ .

1. Carregar dados: Armazenar  $X_{train}$  e  $Y_{train}$  na memória.

2. Para cada instância de teste  $x_{query}$ :

3. Calcular Distâncias:

- Calcular a distância Euclidiana entre  $x_{query}$  e todos os pontos em  $X_{train}$ .
- $d(x_{query}, x_i) = \sum (x_{query} - x_i)^2$

4. Identificar Vizinhos:

- Ordenar as distâncias em ordem crescente.
- Selecionar os índices das  $k$  menores distâncias.
- Recuperar os rótulos (classes)  $Y$  desses  $k$  vizinhos.

5. Contabilizar Votos (Contagem Real):

- Para cada classe única  $c$ , calcular  $count(c)$ : quantos vizinhos pertencem à classe  $c$ .

6. Se kNN Tradicional:

- Retornar a classe com o maior valor de  $count(c)$ .

7. Se kNN com Privacidade (Mecanismo de Laplace):

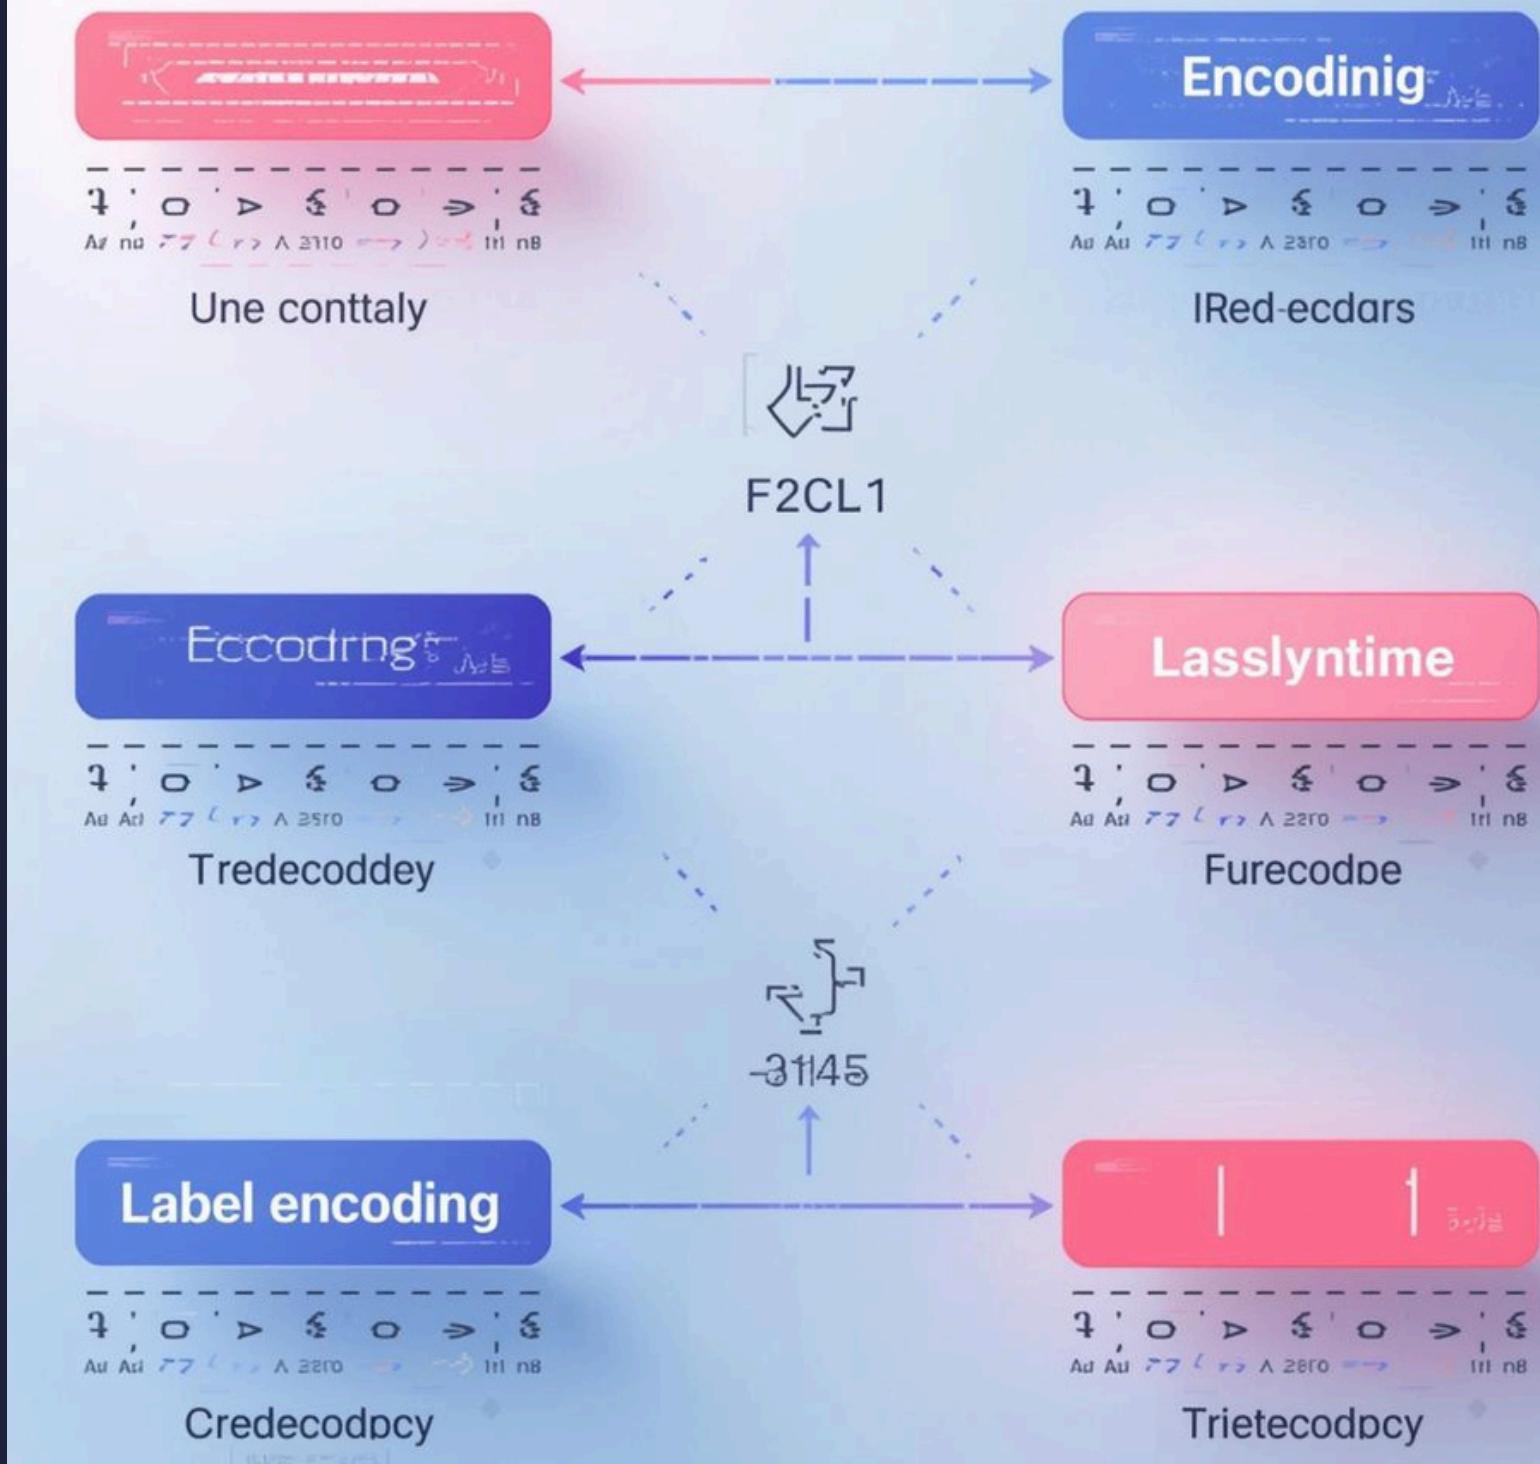
- Definir sensibilidade  $\Delta f = 1$ .
- Calcular o parâmetro de escala  $b = \Delta f / \epsilon$
- Para cada classe  $c$ :
  - Gerar ruído ruido  $Laplace(0, b)$
  - Calcula  $voto\_ruidoso(c) = count(c) + ruido$
- Retornar a  $\max(voto\_ruidoso(c))$ .

# Codificação de Atributos Não Numéricos

No código apresentado, a conversão é feita explicitamente na linha:

```
for col in df.columns:  
    if df[col].dtype == 'object' or pd.api.types.is_categorical_dtype(df[col]):  
        df[col], _ = pd.factorize(df[col])  
    ...
```

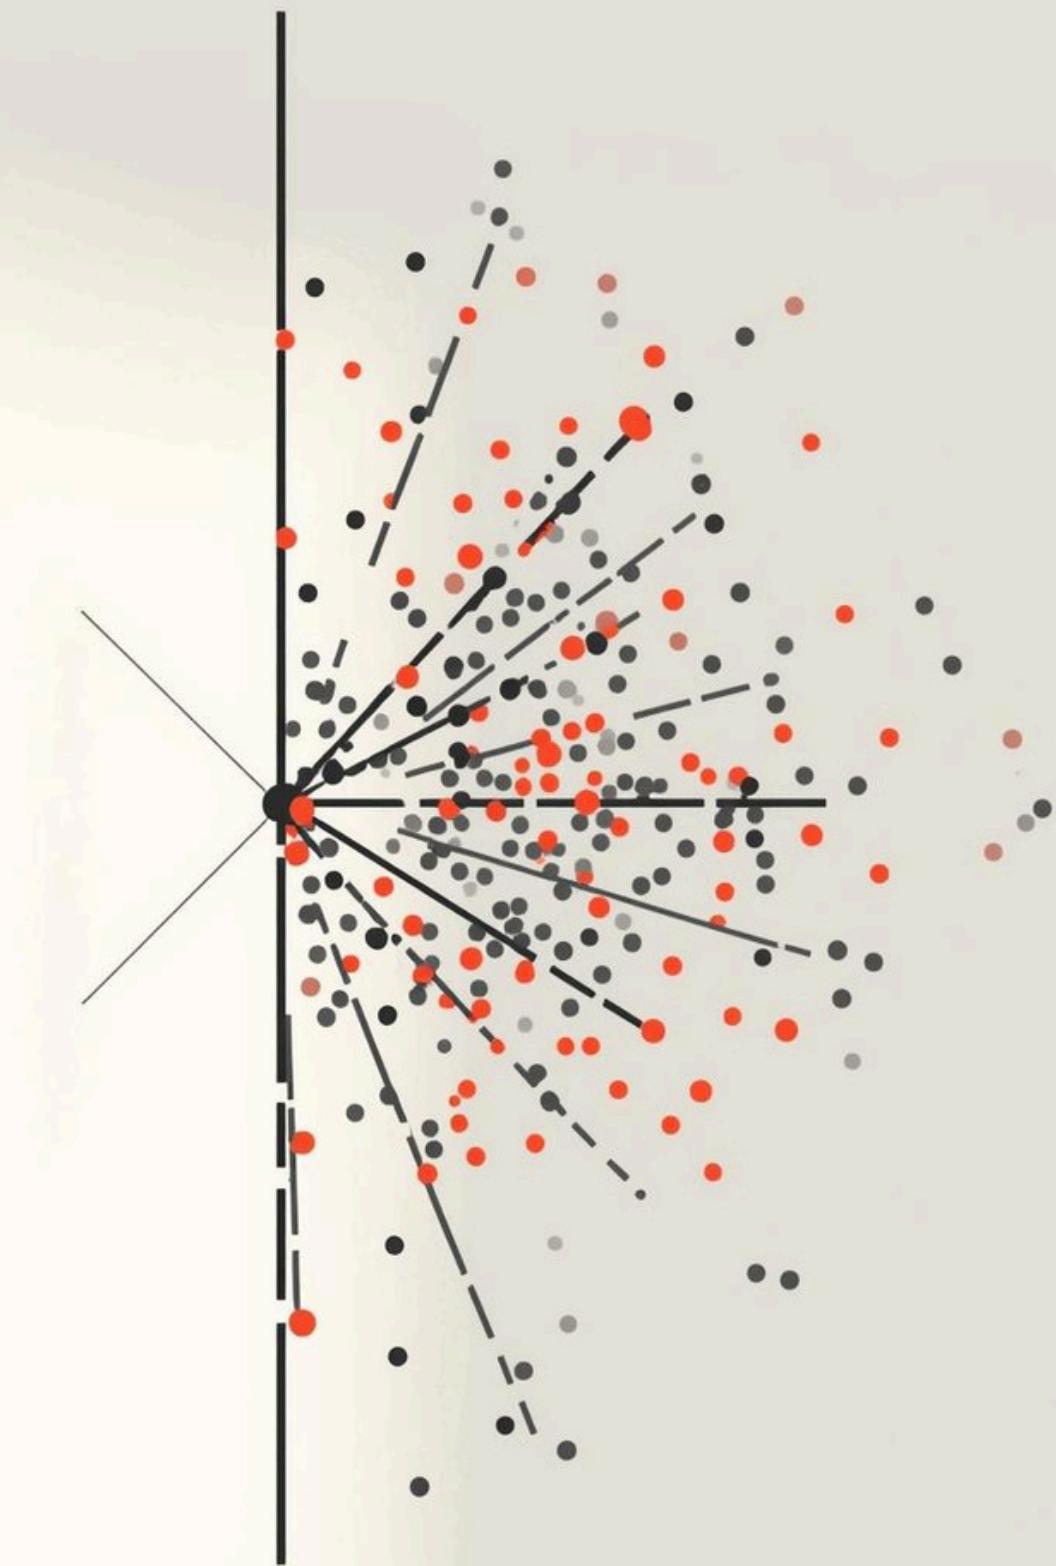
Isso fez com que os dados de categorização ficassem no intervalo entre 1, ..., n, onde n é o número de classes categóricas única da coluna codificada.



# Aplicação do Mecanismo de Laplace

*"O mecanismo de Laplace foi aplicado sobre a contagem de votos das classes vizinhas (histograma de votos). Em vez de simplesmente escolher a classe majoritária entre os k vizinhos, adicionou-se um ruído aleatório extraído de uma distribuição de Laplace, centrado em 0 com escala  $b = 1/\epsilon$ , a cada contagem de classe. A classe predita foi aquela que obteve a maior contagem após a adição do ruído. Isso possivelmente mascara a influência exata de qualquer vizinho individual na decisão final do algoritmo."*

*Pega a contagem → adiciona ruído → escolhe quem ganhou → retorna a classe*



# Orcamento do Mecanismo de Laplace

*O orçamento usado nos mecanismo foi do intervalo de  $\epsilon = [0.5, 1, 1.5, 2.0, 2.5, 3.0]$*

*Motivações :*

*Sugestão da especificação + Construção de Curva de Convergência de Acurácia*



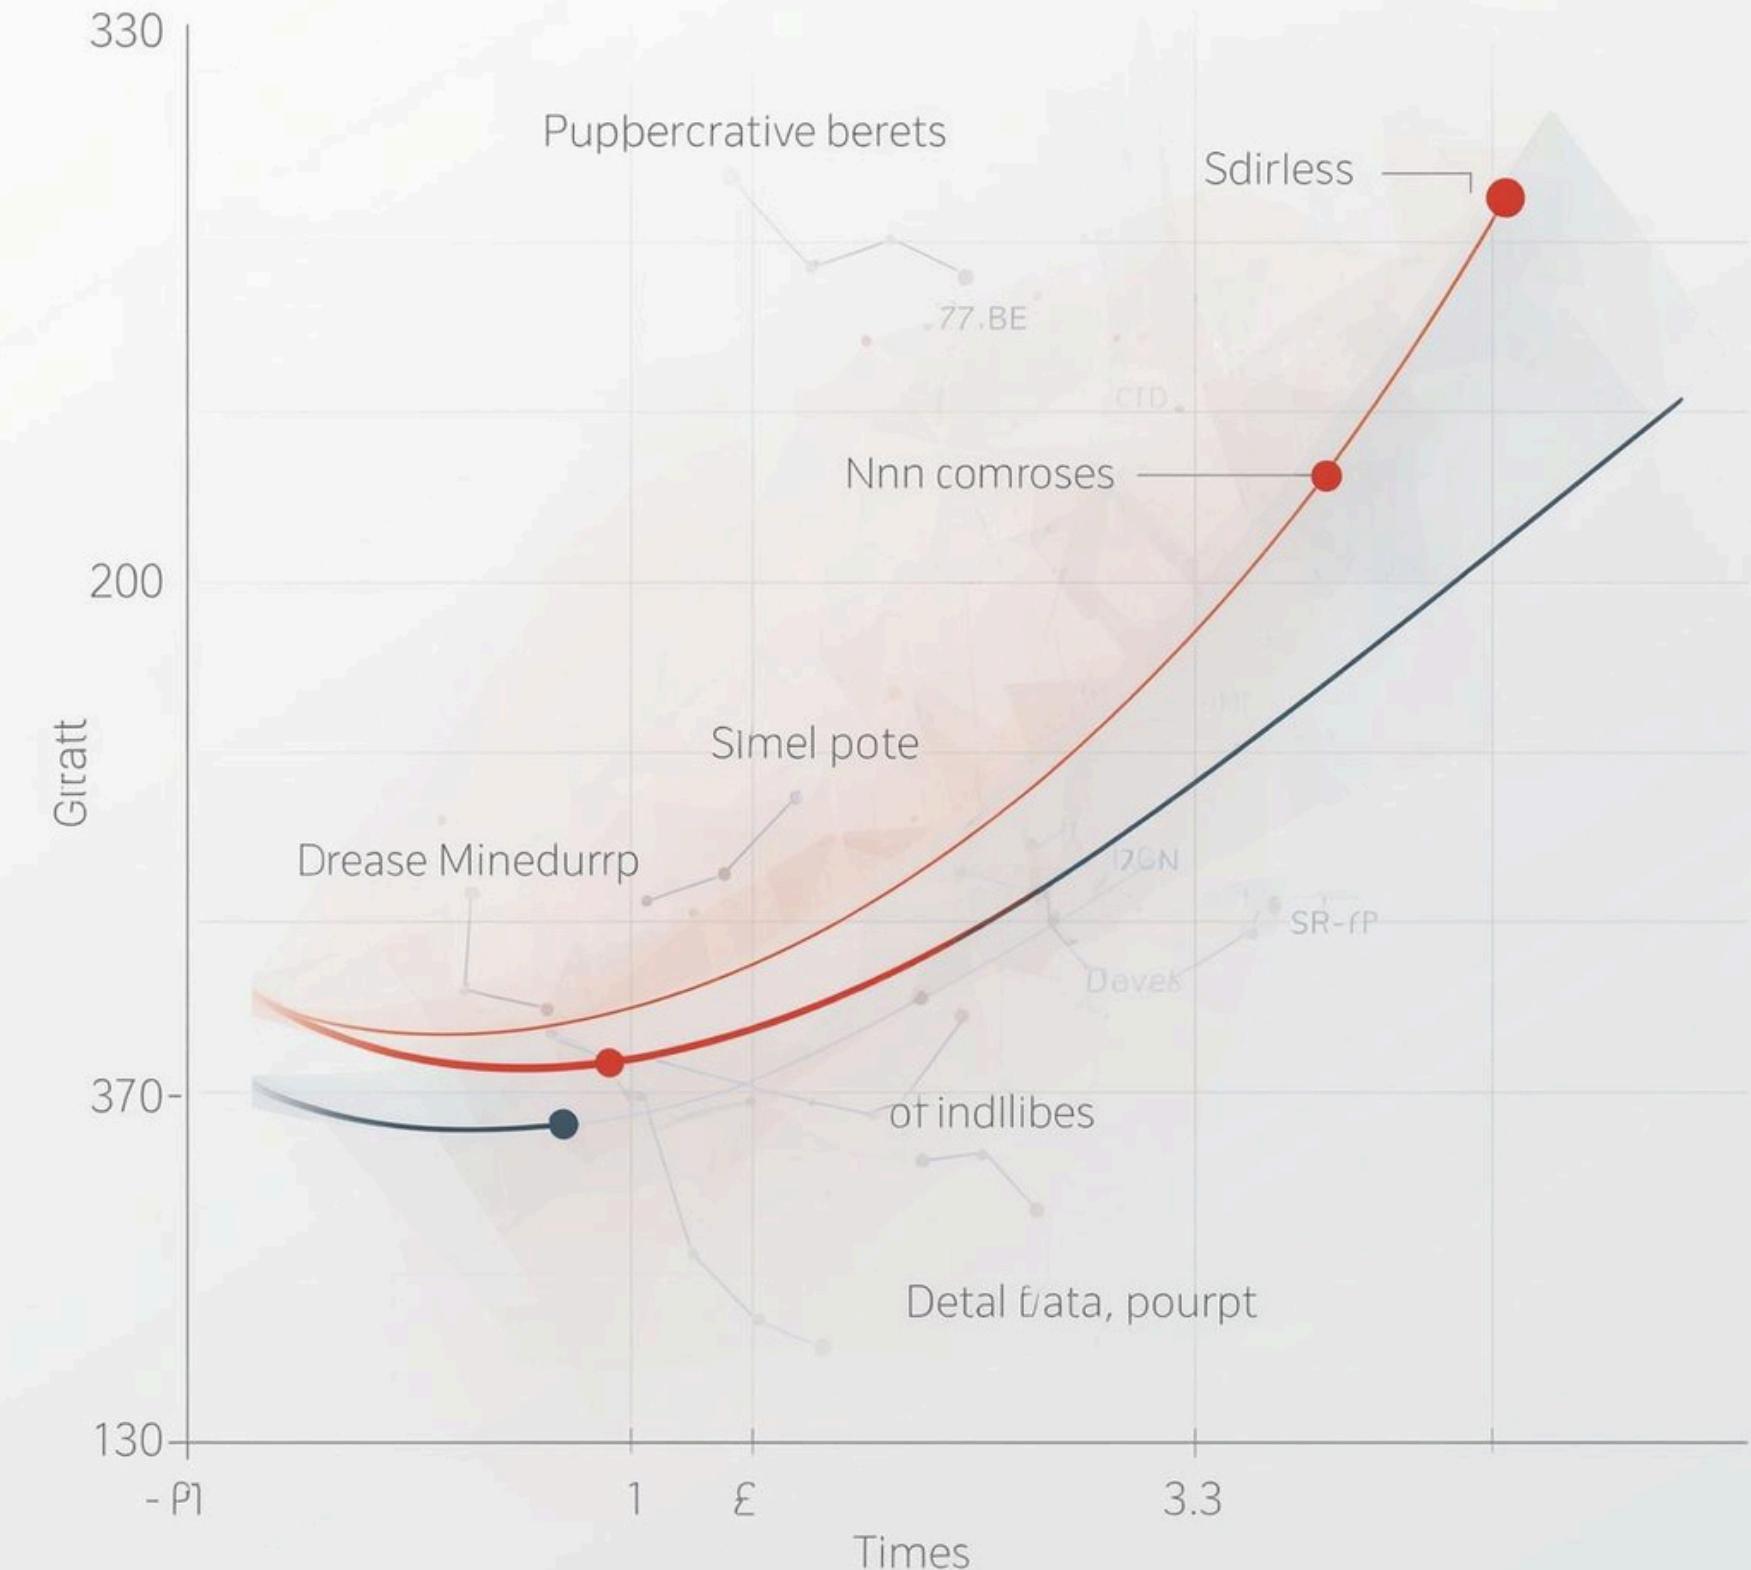
# Sensibilidade

O valor da sensibilidade é  $\Delta f=1$

Isso ocorre porque a função de consulta é uma contagem de votos. Ao modificar, adicionar ou remover um único registro da base de dados de treino, o conjunto de vizinhos em R pode ser alterado.

No pior caso, um vizinho da classe A é substituído por um vizinho da classe B. Isso altera a contagem da classe A em -1 ou da classe B em +1. Portanto, a magnitude máxima da mudança na contagem de qualquer classe dada a alteração de um único indivíduo é 1.

## Global Sensitivity



# Acurácia x Orçamento( $\epsilon$ )

